

EECS 492 实用人工智能复习讲义

Lecture 1–7: 从理性智能体到深度学习与 Transformer

根据课程讲义整理

2026 年 9 月 29 日

摘要

本讲义按 Lecture 1–7 汇总课程中出现的核心概念、定义、算法、假设与公式。重点放在“输入–模型–损失–优化–泛化”的统一视角，并在每章末给出复习抓手。公式中的向量默认是列向量，除非特别说明。

目录

1 Lecture 1: 人工智能与理性智能体	3
1.1 什么是人工智能	3
1.2 理性智能体的基本思想	3
1.3 本章要点	3
2 Lecture 2: 智能体、数学复习与概率	4
2.1 PEAS 与任务环境	4
2.2 智能体类型	4
2.3 向量与矩阵	4
2.4 多元微积分与链式法则	5
2.5 概率基础	5
3 Lecture 3: 机器学习入门	5
3.1 学习类型	5
3.2 训练、验证、测试与泛化	6
4 Lecture 4: 决策树与集成方法	6
4.1 决策树模型	6
4.2 熵与信息增益	6
4.3 树的风险与剪枝	7
4.4 集成方法	7

5 Lecture 5: 线性回归	7
5.1 模型与假设	7
5.2 多元回归与正规方程	7
5.3 梯度下降	8
5.4 回归评估	8
6 Lecture 6: 神经网络与深度学习	8
6.1 单个神经元	8
6.2 前馈神经网络	9
6.3 二元交叉熵与反向传播	9
6.4 卷积神经网络 (CNN) 概念	9
7 Lecture 7: 自注意力与 Transformer	9
7.1 动机与输入表示	9
7.2 从直觉到公式: 注意力	9
7.3 Query、Key、Value 与缩放点积	10
7.4 多头注意力与 Transformer block	10
7.5 Encoder-Decoder、预训练与微调	10
7.6 局限与比较	11
8 总复习: 统一框架与高频易错点	11
8.1 统一的机器学习训练框架	11
8.2 高频易错点	11
8.3 建议的考前自测	11

1 Lecture 1: 人工智能与理性智能体

1.1 什么是人工智能

人工智能 (AI) 可以从四种经典观点理解:

1. **像人一样思考**: 研究人的认知过程, 再让机器模拟; 依赖内省、心理学实验、脑成像和认知科学。
2. **像人一样行动**: 以图灵测试为代表, 要求机器在自然语言、知识表示、自动推理和学习方面表现得像人; 完全图灵测试还包括视觉、语音和机器人操作。
3. **理性地思考**: 使用逻辑和形式规则推导正确结论, 例如“苏格拉底是人; 所有人都会死; 所以苏格拉底会死”。局限包括知识不完备、计算复杂度高和现实中的不确定性。
4. **理性地行动**: 把 AI 看作在不确定性下选择行动的智能体, 目标是在给定信息、时间与资源限制下最大化期望表现。

课程的主线是设计理性智能体, 涉及搜索、问题求解、不确定性、学习、逻辑、决策树、回归、神经网络和 Transformer。课程还强调: 目标函数不一定能完整表达人类价值, 因此需要关注价值对齐、谨慎行动、征求许可以及保留人的控制权。

1.2 理性智能体的基本思想

智能体 (agent) 是能够通过传感器感知环境、通过执行器作用于环境, 并自主追求目标或策略的实体。智能体在时刻 t 接收到感知序列

$$p_{1:t} = (p_1, p_2, \dots, p_t),$$

并由智能体函数选择行动

$$a_t = \pi(p_{1:t}).$$

理性并不意味着永远正确, 而是指: 对已有的感知序列、先验知识和可用行动, 选择使期望性能度量最大的行动:

$$a_t^* = \operatorname{argmax}_{a \in A} \mathbb{E}[U \mid p_{1:t}, a].$$

性能度量应描述希望世界达到的状态, 例如自动驾驶应安全、合法、舒适、快速并减少对他人的负面影响, 而不是简单规定“必须执行某一个动作”。

1.3 本章要点

- AI 的四种观点要区分“思考/行动”和“像人/理性”。
- 理性智能体以期望性能为准, 而不是以设计者预设的动作列表为准。
- 现实 AI 的关键困难往往来自不确定性、目标不完整以及人类价值难以形式化。

2 Lecture 2: 智能体、数学复习与概率

2.1 PEAS 与任务环境

用 PEAS 描述任务环境: **P**erformance measure (性能度量)、**E**nvironment (环境)、**A**ctuators (执行器)、**S**ensors (传感器)。例如自动驾驶穿梭车: 性能包括安全、快速、舒适、守法和盈利; 环境包括道路、交通、行人、乘客和天气; 执行器包括方向盘、油门、刹车、转向灯和语音; 传感器包括摄像头、雷达、GPS、速度计和加速度计。

任务环境的七个维度:

1. **完全可观测/部分可观测**: 能否在每个时刻获得环境状态的完整信息; 噪声传感器和缺失信息会导致部分可观测。
2. **确定性/非确定性**: 当前状态和行动是否完全决定下一状态。
3. **片段式/序贯式**: 当前行动是否影响未来决策。
4. **静态/动态**: 智能体思考时世界是否仍在变化。
5. **离散/连续**: 状态、感知或行动的数量是否有限或可数。
6. **已知/未知**: 行动结果和环境规律是否已知; 未知时智能体需要学习环境模型。
7. **单智能体/多智能体**: 是否存在其他会影响结果的智能体。

2.2 智能体类型

简单反射智能体 只根据当前感知做条件-行动映射, 形式类似“若当前位置脏则清扫”。简单但无法处理隐藏状态和长期后果。

基于模型的反射智能体 维护内部状态/信念, 并使用关于世界如何变化的模型推断当前状态。

基于目标的智能体 除模型外还知道期望状态, 选择能到达目标的行动。

基于效用的智能体 比较不同路径和目标状态的相对好坏, 用效用函数处理多目标与权衡。

学习智能体 从经验中改进环境模型、策略或效用; 可适应设计者无法预见的情况。

2.3 向量与矩阵

向量是有序数列, 默认写成列向量: $\mathbf{x} = (x_1, \dots, x_n)^T$ 。基本操作为

$$\mathbf{x} + \mathbf{y} = (x_1 + y_1, \dots, x_n + y_n)^T, \quad c\mathbf{x} = (cx_1, \dots, cx_n)^T.$$

范数 (长度) 为 $\|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}$; 点积为

$$\mathbf{x} \cdot \mathbf{y} = \sum_i x_i y_i = \|\mathbf{x}\| \|\mathbf{y}\| \cos \theta.$$

矩阵 $A \in \mathbb{R}^{m \times n}$ 是 m 行 n 列数组。加法要求形状相同; 乘法要求内维匹配: 若 $A \in \mathbb{R}^{m \times n}$ 、 $B \in \mathbb{R}^{n \times p}$, 则

$$(AB)_{ij} = \sum_{k=1}^n A_{ik} B_{kj}, \quad AB \in \mathbb{R}^{m \times p}.$$

矩阵乘法通常不交换, 但满足结合律。单位矩阵 I 满足 $AI = IA = A$; 转置满足 $(A^T)_{ij} = A_{ji}$; 可逆矩阵满足 $A^{-1}A = I$, 并非所有方阵可逆。

2.4 多元微积分与链式法则

标量函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的梯度为

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)^T.$$

梯度指向局部增长最快的方向，负梯度是局部下降最快的方向。标量链式法则为

$$z = g(x), y = f(z) \implies \frac{dy}{dx} = \frac{dy}{dz} \frac{dz}{dx}.$$

若 $z_j = g_j(\mathbf{x})$ 、 $y = f(\mathbf{z})$ ，则

$$\frac{\partial y}{\partial x_k} = \sum_j \frac{\partial y}{\partial z_j} \frac{\partial z_j}{\partial x_k}.$$

这正是反向传播的数学基础：从损失对输出的导数开始，沿计算图反向乘上局部导数。

2.5 概率基础

样本空间 Ω 是有可能结果的集合；结果记为 ω ；事件是 Ω 的子集；随机变量 X 为结果赋值。离散分布用概率质量函数，连续分布用概率密度函数。概率满足 Kolmogorov 公理：

$$P(e) \geq 0, \quad P(\Omega) = 1, \quad P(A \cup B) = P(A) + P(B) \quad (A \cap B = \emptyset).$$

常用关系为

$$P(\neg A) = 1 - P(A), \quad P(A \cup B) = P(A) + P(B) - P(A \cap B),$$

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(A \cap B) = P(A | B)P(B).$$

贝叶斯公式：

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}, \quad P(A) = \sum_i P(A | B_i)P(B_i).$$

期望和方差：

$$\mathbb{E}[X] = \sum_x xP(x), \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

独立意味着 $P(A \cap B) = P(A)P(B)$ ；独立不等于互斥。

3 Lecture 3: 机器学习入门

3.1 学习类型

学习的判据是：观察世界后，在未来任务上性能提高。**强化学习**从奖励/惩罚序列学习，通常建立在 MDP/POMDP 上；**无监督学习**没有显式标签，目标是发现输入结构；**监督学习**观察输入-输出样本，学习映射 $h: \mathcal{X} \rightarrow \mathcal{Y}$ ；**自监督学习**从数据自身构造监督信号。

无监督学习的经典任务是 k -means 聚类。给定 n 个点和 k 个簇，Lloyd 算法反复执行：随机初始化质心；将每点分给最近质心；用簇内平均值更新质心；直到分配不再变化。其目标函数为

$$J(\{\mu_j\}) = \sum_{i=1}^n \left\| \mathbf{x}^{(i)} - \boldsymbol{\mu}_{c(i)} \right\|_2^2, \quad c(i) = \underset{j}{\operatorname{argmin}} \left\| \mathbf{x}^{(i)} - \boldsymbol{\mu}_j \right\|_2.$$

算法通常收敛到局部最优，结果受初始化和 k 影响。

监督学习给定训练样本 $D = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$ ，未知目标函数 f ，假设空间 H 和学习算法 A 产生假设 $h = A(D) \in H$ ，用 $h(\mathbf{x})$ 近似 $f(\mathbf{x})$ 。分类输出离散类别，回归输出连续数值。

3.2 训练、验证、测试与泛化

训练集用于学习参数；验证集用于选择模型和超参数；测试集只用于最终泛化评估。不能反复根据测试集调参，否则测试集不再是无偏的最终评估。 k 折交叉验证将训练/验证数据分成 k 份，每次用一份验证、其余训练，报告 k 次结果的平均值，最后用全部训练数据重训并在测试集上评估。

偏差-方差权衡：偏差高表示模型表达能力不足、训练误差也可能较大；方差高表示模型对训练样本波动敏感。模型过简单会欠拟合，模型过复杂会过拟合。增加复杂度通常降低偏差但增加方差；正则化、更多数据、交叉验证和集成方法可改善泛化。

4 Lecture 4: 决策树与集成方法

4.1 决策树模型

决策树是分类监督学习模型。内部节点测试某个属性，边表示属性取值，叶节点给出类别。预测时从根开始沿测试结果走到叶。目标是用尽可能少的测试正确分类训练样本。

经典决策树学习是贪心的分治递归：若样本为空，返回父节点样本中的多数类；若样本全同类，返回该类；若没有属性但仍有冲突，返回多数类；否则选择重要性最高的属性作为根，对每个取值递归学习子树。

4.2 熵与信息增益

随机变量 V 的熵为

$$H(V) = - \sum_k P(v_k) \log_2 P(v_k).$$

确定结果的熵为 0，公平二元变量熵为 1 bit，公平四面骰熵为 2 bit。布尔熵写作

$$B(q) = -q \log_2 q - (1 - q) \log_2 (1 - q).$$

属性 A 将样本分成 $E_1, \dots, E_d$ ，则条件熵/剩余信息为

$$\text{Remainder}(A) = \sum_{k=1}^d \frac{|E_k|}{|E|} H(Y | E_k),$$

信息增益为

$$\text{Gain}(A) = H(Y) - \text{Remainder}(A).$$

选择信息增益最大的属性。直觉是：好的划分能让每个子集更“纯”。

4.3 树的风险与剪枝

决策树容易过拟合，尤其在噪声多、属性多或树很深时。剪枝删除只拟合噪声的测试；停止分裂、限制深度、设置叶节点最小样本数也能降低方差。需要注意，训练数据不会直接存进树，树只保留测试规则；未见过的属性组合和错误/噪声会导致错误。

4.4 集成方法

集成将多个基础模型的输出组合起来，可降低偏差、降低方差或两者兼顾。分类常用多数投票，回归常用平均：

$$h(\mathbf{x}) = \frac{1}{K} \sum_{i=1}^K h_i(\mathbf{x}).$$

Bagging 从原训练集有放回采样产生 K 个数据集，分别训练模型并投票/平均，主要降低方差。

随机森林 在 bagging 决策树基础上，每次分裂只随机考虑一部分属性，增加树之间的多样性，得到许多复杂但不完全相同的树。

Boosting 维护样本权重：先训练 h_1 ，提高被错分样本权重、降低正确样本权重，再训练后续模型；最终按模型表现加权组合。形式可写为 $h(\mathbf{x}) = \sum_i z_i h_i(\mathbf{x})$ 。

5 Lecture 5: 线性回归

5.1 模型与假设

回归预测连续 y ，单变量线性模型为

$$y = w_0 + w_1 x + \varepsilon.$$

这里 w_0 是截距， w_1 是斜率， ε 是随机误差。经典假设：误差均值为 0；误差方差恒定为 σ^2 ；误差服从高斯分布；不同观测的误差相互独立。

对 n 个样本，平方误差损失 (SSE) 为

$$\mathcal{L}(\mathbf{w}) = \sum_{i=1}^n (y_i - (w_0 + w_1 x_i))^2.$$

平方损失是凸函数，因此在线性回归中没有坏的局部极小点。单变量解析解为

$$w_1 = \frac{n \sum_i x_i y_i - (\sum_i x_i)(\sum_i y_i)}{n \sum_i x_i^2 - (\sum_i x_i)^2}, \quad w_0 = \frac{\sum_i y_i - w_1 \sum_i x_i}{n}.$$

5.2 多元回归与正规方程

有 k 个特征时，将截距吸收进 $x_{i0} = 1$ ：

$$h_{\mathbf{w}}(\mathbf{x}_i) = \sum_{j=0}^k w_j x_{ij} = \mathbf{w}^T \mathbf{x}_i.$$

将样本排成设计矩阵 X ，目标向量为 $\mathbf{y}$ ，则

$$\mathcal{L}(\mathbf{w}) = \|\mathbf{y} - X\mathbf{w}\|_2^2, \quad \mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{y},$$

前提是 $X^T X$ 可逆。矩阵很大、病态或需要在线学习时，梯度下降更实用。

5.3 梯度下降

一般更新式为

$$w_j \leftarrow w_j - \alpha \frac{\partial \mathcal{L}}{\partial w_j},$$

其中 $\alpha > 0$ 是学习率。对平方损失，可按误差方向写成

$$w_0 \leftarrow w_0 + \alpha \frac{1}{n} \sum_i (y_i - h_{\mathbf{w}}(\mathbf{x}_i)),$$

$$w_j \leftarrow w_j + \alpha \frac{1}{n} \sum_i (y_i - h_{\mathbf{w}}(\mathbf{x}_i)) x_{ij}.$$

批量梯度下降每次使用全部样本，步子稳定且在足够小学习率下可收敛；随机梯度下降每次使用一个样本或小批量，计算快、噪声大、未必严格收敛，但适合大数据。

5.4 回归评估

决定系数

$$R^2 = 1 - \frac{SS_{\text{RES}}}{SS_{\text{TOT}}}, \quad SS_{\text{RES}} = \sum_i (y_i - \hat{y}_i)^2, \quad SS_{\text{TOT}} = \sum_i (y_i - \bar{y})^2.$$

$R^2 = 1$ 表示完美拟合， $R^2 = 0$ 表示模型不比用均值预测更好；实际使用时要结合测试集、残差图和任务目标。

6 Lecture 6: 神经网络与深度学习

6.1 单个神经元

神经元先做线性组合，再施加非线性激活：

$$z = \mathbf{w}^T \mathbf{x} + b = \sum_i w_i x_i + b, \quad a = y = g(z).$$

若没有非线性，多层线性层仍可合并为一层线性变换，不能表示复杂边界；激活函数是深度网络表达能力的关键。

常见激活：

$$\text{step: } g(s) = \begin{cases} 1 & s > 0 \\ 0 & \text{otherwise} \end{cases}; \quad \text{sigmoid}(s) = \frac{1}{1 + e^{-s}}, \quad \text{sigmoid}'(s) = \text{sigmoid}(s)(1 - \text{sigmoid}(s));$$

$$\tanh(s) = \frac{e^s - e^{-s}}{e^s + e^{-s}}, \quad \text{ReLU}(s) = \max(0, s), \quad \text{ReLU}'(s) = \begin{cases} 1 & s > 0 \\ 0 & \text{otherwise} \end{cases}.$$

阶跃函数不可导；sigmoid 输出在 $(0, 1)$ ；tanh 输出在 $(-1, 1)$ ；ReLU 产生稀疏激活且计算简单，但可能有“死亡 ReLU”问题。

6.2 前馈神经网络

多层感知机 (MLP/全连接网络) 没有环, 后一层接收前一层输出。对第 l 层:

$$\mathbf{z}^{[l]} = W^{[l]} \mathbf{a}^{[l-1]} + \mathbf{b}^{[l]}, \quad \mathbf{a}^{[l]} = g^{[l]}(\mathbf{z}^{[l]}).$$

其中 $\mathbf{a}^{[0]} = \mathbf{x}$, 最后一层输出预测。也可添加常数节点 $a_0 = 1$, 把偏置吸收到权重中。

6.3 二元交叉熵与反向传播

二分类通常用 sigmoid 输出 $\hat{y} \in (0, 1)$, 二元交叉熵为

$$\mathcal{L}(W) = -\frac{1}{n} \sum_{i=1}^n \left[y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right].$$

真实标签概率分布为 A 、预测分布为 B 时, 交叉熵

$$H(A, B) = - \sum_k P_A(k) \log P_B(k).$$

预测越确信但越错误, 损失增长越快。训练就是对所有权重反复执行梯度下降; 反向传播使用链式法则高效计算每层梯度。

6.4 卷积神经网络 (CNN) 概念

CNN 适合图像等具有局部结构的数据。卷积核在输入上滑动, 通过局部连接和权重共享提取边缘、纹理、形状等特征; 多层卷积逐渐形成更抽象表示。典型组件包括卷积、非线性激活、池化/下采样和全连接层。局部感受野减少参数, 权重共享带来平移相关的归纳偏置; 代价是对全局关系的建模需要更深层或额外机制。

7 Lecture 7: 自注意力与 Transformer

7.1 动机与输入表示

Transformer 将一个输入向量序列映射为同长度输出序列, 由 Transformer block 堆叠而成, 核心组件是自注意力和前馈网络。相比按时间顺序逐个计算隐藏状态的循环方法, 自注意力在训练时能并行处理序列位置, 并直接连接任意距离的上下文。

词嵌入把离散词映射为连续向量, 位置嵌入表示词在序列中的位置。输入通常为

$$\mathbf{x}_i = \text{word-embedding}_i + \text{positional-embedding}_i.$$

嵌入的目标是让语义或其他有用结构在连续向量空间中体现出来。

7.2 从直觉到公式: 注意力

注意力回答“当前元素应关注输入的哪些部分”。最简单的自注意力以点积作为相似度:

$$s_{ij} = \mathbf{x}_i \cdot \mathbf{x}_j, \quad \alpha_{ij} = \frac{e^{s_{ij}}}{\sum_k e^{s_{ik}}}, \quad \mathbf{y}_i = \sum_j \alpha_{ij} \mathbf{x}_j.$$

因此注意力包含三步：比较相关性；用 softmax 归一化为概率权重；按权重求和。Softmax 定义为

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}},$$

输出非负且总和为 1。数值实现常减去 $\max_i z_i$ ：

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i - m}}{\sum_j e^{z_j - m}}, \quad m = \max_j z_j.$$

7.3 Query、Key、Value 与缩放点积

每个输入向量通过三个不同的线性投影承担三种角色：

$$\mathbf{q}_i = W^Q \mathbf{x}_i, \quad \mathbf{k}_i = W^K \mathbf{x}_i, \quad \mathbf{v}_i = W^V \mathbf{x}_i.$$

查询与键比较，值参与输出。为避免点积维数增大导致 logits 过大、softmax 饱和和梯度不稳定，使用缩放点积：

$$s_{ij} = \frac{\mathbf{q}_i^T \mathbf{k}_j}{\sqrt{d_k}}, \quad \alpha_{ij} = \frac{\exp(s_{ij})}{\sum_r \exp(s_{ir})}, \quad \mathbf{y}_i = \sum_j \alpha_{ij} \mathbf{v}_j.$$

矩阵形式（忽略掩码）为

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V.$$

因果语言模型会遮住未来位置，使位置 i 只能看见过去和当前位置；编码器通常可以看双向上下文。

7.4 多头注意力与 Transformer block

不同关系可能同时存在，例如主语-动词、代词-指代词、局部句法和长距离语义。多头注意力用多组独立参数并行计算：

$$\text{head}_r = \text{Attention}(QW_r^Q, KW_r^K, VW_r^V),$$

再拼接并线性投影：

$$\text{MHA}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O.$$

每个 head 可学习不同关系。标准 block 还包含位置逐点前馈网络（通常是两层 MLP）、残差连接和归一化；它们分别提供非线性变换、稳定梯度并改善优化。

7.5 Encoder-Decoder、预训练与微调

机器翻译等序列到序列任务常采用 encoder-decoder：编码器读源序列并构造表示，解码器逐步生成目标序列；解码器可通过交叉注意力读取编码器输出。三类语言模型结构及典型用途：

- 解码器模型（GPT、Claude、Llama 等）：自回归生成，不能条件化未来词。
- 编码器模型（BERT 等）：双向上下文，适合表示学习和理解任务。
- 编码器-解码器模型（T5、Whisper 等）：适合翻译、摘要、语音到文本等输入到输出任务。

语言建模是学习序列概率，利用链式法则

$$P(w_{1:T}) = \prod_{t=1}^T P(w_t | w_{<t}),$$

通常最小化负对数似然/交叉熵。**预训练**在海量无标注文本上学习通用表示；**微调**在具体下游任务数据上继续用梯度下降训练，常在顶层增加分类器。预训练提供通用语言知识，微调将其适配到有限的任务标签。

7.6 局限与比较

自注意力的单层计算可直接连接长距离位置且易并行，但标准全注意力对长度 n 的时间和空间复杂度通常为 $O(n^2)$ ；上下文窗口有限，注意力权重不一定等于可靠解释，模型还可能继承数据偏差。卷积有局部性和位置敏感性；单头自注意力是加权平均；多头注意力用多个投影同时学习不同关系。

8 总复习：统一框架与高频易错点

8.1 统一的机器学习训练框架

几乎所有监督模型都可写成：给定数据 D 、模型 h_θ 和损失 $\mathcal{L}$ ，求

$$\theta^* = \operatorname{argmin}_{\theta} \frac{1}{n} \sum_{i=1}^n \ell(h_\theta(\mathbf{x}^{(i)}), y^{(i)}) + \lambda \Omega(\theta).$$

决策树通过信息增益贪心分裂；线性回归通过平方误差和解析解/梯度下降学习；神经网络通过交叉熵和反向传播学习；Transformer 只是使用特殊的注意力结构来参数化 h_θ 。 $\lambda \Omega(\theta)$ 表示正则化，可抑制过拟合。

8.2 高频易错点

1. 理性不等于全知：理性是在当前信息下最大化期望表现。
2. 互斥与独立不同；条件概率的分母不能漏掉。
3. 熵越大代表越不确定；信息增益是分裂前熵减去分裂后的期望熵。
4. 训练误差低不代表泛化好；测试集不能参与调参。
5. 解析解要求矩阵条件良好；梯度下降的学习率过大可能发散，过小则收敛慢。
6. sigmoid 适合二分类输出；多分类通常用 softmax 与 categorical cross-entropy。
7. 在注意力中，query 用来发起匹配，key 用来被匹配，value 被加权汇总；缩放因子是 $\sqrt{d_k}$ ，不是 d_k 。
8. 自注意力可并行不等于没有代价：全连接位置关系带来 $O(n^2)$ 复杂度。

8.3 建议的考前自测

1. 给一个 PEAS 场景，判断其七个任务环境维度并说明理由。
2. 手算一个向量点积、矩阵乘法、梯度和链式法则例子。

3. 给定 p, n 或各子集计数，计算熵、剩余信息和信息增益。
4. 推导一元线性回归的 w_0, w_1 ，并比较正规方程、批量 GD、SGD。
5. 写出一个两层网络的前向计算、二元交叉熵以及一条反向梯度链。
6. 给定 Q, K, V ，逐步计算缩放点积注意力、softmax 权重和加权输出。
7. 解释为什么位置嵌入、因果掩码、多头注意力、预训练和微调分别必要。